



中国人民大学本科毕业论文 (设计)

公司新闻对股票收益率的影响

——基于 Raven Pack 新闻数据与 TAQ 高频交易数据集

作者: 吕秋燃
学院: 高瓴人工智能学院高礼研究院
专业: 金融学
年级: 2019 级
学号: 2019202399
指导教师: 袁佩轩
论文成绩: 90
完成日期: 2023 年 5 月 18 日

中国人民大学学位论文原创性声明和使用授权说明

原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不含任何其他个人或集体已经发表或撰写过的作品或成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

论文作者签名：

吕秋燃

日期：2023 年 4 月 20 日

学位论文使用授权说明

本人完全了解中国人民大学关于收集、保存、使用学位论文的规定，即：

- 按照学校要求提交学位论文的印刷本和电子版本；
- 学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

论文作者签名：

吕秋燃

指导教师签名：

袁佩轩

日期：2023 年 4 月 20 日



摘要

预测股市收益率一直是分析师和研究人员感兴趣的话题。由于其高度波动性取决于不同的政治和经济因素、领导层更迭、投资者情绪和许多其他因素，股票收益率很难预测。而利用新闻数据进行股票市场预测具有很高的应用前景和研究价值。新闻中不仅包含对市场有冲击的事件信息还包括人们的情感倾向。本论文基于 Raven Pack 新闻数据集及 TAQ 股票高频交易数据集，建立了混合线性回归、回归树、以及神经网络三个模型，试图捕捉新闻数据对股票高频交易收益率的关系。从回归系数对应不同时间区间的显著性上，本论文在实证上发现了一些新闻变量在股票交易市场上的延迟响应，以及随着时间的推移，一些变量的影响逐渐消失。利用新闻信息来预测未来时间区间，从测试集的预测效果上，本论文发现线性模型无法捕捉新闻数据对股票高频交易的信息，而回归树和神经网络能够捕捉更多的非线性关系，得到更好的预测效果。

关键词：股票市场 高频交易数据 机器学习 神经网络 信息延迟响应

Abstract

Predicting stock market returns has always been a topic of interest for analysts and researchers. Stock returns are difficult to predict because of their high volatility depending on different political and economic factors, leadership changes, investor sentiment and many other factors. And the use of news data for stock market forecasting is highly promising in application and research value. News not only contains information about events that have an impact on the market but also includes people's emotional tendencies. Based on Raven Pack news dataset and TAQ stock high-frequency trading dataset, we build three models, including mixed linear regression, regression tree, and neural network to try to capture the relationship between news data on stock high-frequency trading returns. In terms of the significance of the regression coefficients corresponding to different time intervals, we empirically find the delayed corresponding of some news variables in the stock trading market, as well as the fading effect of some variables over time. Using news information to predict future time intervals, in terms of the predictive effect of the test set, we find that linear models cannot capture the information of news data on high frequency stock trading, while regression trees and neural networks are able to capture more nonlinear relationships and get better prediction results.

Key Words: Stock Market High-frequency Data Machine Learning Neural-Network
Information delay response



内容目录

1	研究背景	1
1.1	背景介绍	1
1.2	文献综述	1
1.3	本论文主要内容	3
2	数据介绍及处理	5
2.1	Raven Pack 数据集	5
2.2	TAQ 数据集	5
2.3	数据清洗	6
2.4	新闻时刻确定	6
3	数据描述	7
3.1	描述性统计	7
3.2	训练集、验证集与测试集的划分	10
3.3	模型评判标准	11
4	研究方法及结果	12
4.1	多元线性回归：加入新闻变量与公司变量	12
4.2	其他线性回归	13
4.3	回归树	14
4.4	神经网络	14
4.5	实验结果	15
4.5.1	全部数据回归	16
4.5.2	回归树	18
4.5.3	神经网络	19
5	总结	20
	参考文献	23
	附录	27
	致谢	31



图/表目录

1	研究背景	1
1.1	背景介绍	1
1.2	文献综述	1
1.3	本论文主要内容	3
2	数据介绍及处理	5
2.1	Raven Pack 数据集	5
2.2	TAQ 数据集	5
2.3	数据清洗	6
2.4	新闻时刻确定	6
3	数据描述	7
3.1	描述性统计	7
3.2	训练集、验证集与测试集的划分	10
3.3	模型评判标准	11
4	研究方法及结果	12
4.1	多元线性回归：加入新闻变量与公司变量	12
4.2	其他线性回归	13
4.3	回归树	14
4.4	神经网络	14
4.5	实验结果	15
4.5.1	全部数据回归	16
4.5.2	回归树	18
4.5.3	神经网络	19
5	总结	20
	参考文献	23
	附录	27
	致谢	31

1 研究背景

1.1 背景介绍

长期以来，预测股市收益率一直是分析师和研究人员感兴趣的话题。股票收益率很难预测，因为其高度波动性取决于不同的政治和经济因素、领导层更迭、投资者情绪和许多其他因素。仅根据历史数据或文本信息预测股票收益率已被证明是不足的。

随着互联网技术的迅猛发展，新闻信息变得越来越容易获取，而这些新闻信息往往与股票市场密切相关。因此，利用新闻数据进行股票市场预测已经成为了一个热门的研究领域。高频交易数据作为股票市场最直观的数据之一，其数据量庞大、时效性强，对于股票市场的预测具有重要意义。而结合新闻数据对高频交易数据进行预测，可以更加准确地把握市场走势，提高投资效益。

现有的研究表明，利用新闻数据进行股票市场预测具有很高的应用前景和研究价值。一些研究者采用基于情感分析的方法，通过对新闻数据中的情感信息进行分析，实现对股票市场的预测[1, 2, 3]。现有的情绪分析研究已经发现，股价走势与新闻文章发表之间存在很强的相关性。已有研究者尝试使用支持向量机、朴素贝叶斯回归和深度学习等算法在不同层次上进行多项情绪分析研究。然而，深度学习算法的准确性取决于提供的训练数据量，在过去的研究中收集和分析的文本数据量不足，因此导致预测的准确性较低[2]。

1.2 文献综述

资产定价理论有很长的历史，它将信息流的数量和质量与资产价格的变化联系起来。例如，导致公司未来前景的不确定性得到解决的信息会导致当前价格的修正。根据这种观点，影响价格变动的一个重要过程是新闻到达过程。已有的文献对于在新闻对股票市场的影响研究，包括影响的机制、影响因素、影响程度、对股票市场的直接影响和间接影响。

新闻对股票市场的直接影响新闻对股票市场的直接影响是指新闻直接影响投资者的决策，进而影响股票市场的价格和波动性。新闻对股票市场的间接影响是指新闻通过影响投资者的心理状态和预期，进而影响股票市场的价格和波动性。

新闻对股票市场的影响机制主要有两种：信息传递和情绪传染。信息传递是指新闻中的信息能够影响投资者的决策，进而影响股票市场。情绪传染是指新闻中的情绪能够感染投资者，引发市场情绪波动，进而影响股票市场。这两种机制相互作用，共同影响股票市场。

新闻对股票市场的影响因素主要包括新闻类型、发布时间、新闻内容、新闻来源等。研究表明，不同类型的新闻对股票市场的影响不同，市场利好消息会带来上涨，市场利空消息则会引发下跌。同时，新闻发布时间也会影响市场反应，尤其是在非交易时间发布的新闻，可能会引发“周末效应”。此外，新闻内容和来源也会对市场产生不同的影响。

新闻对股票市场的影响程度也有所不同。一些研究表明，一些重大事件或重要新闻发布会对市场产生较大的影响，如经济数据公布、政策变动、公司业绩公布等。而一些日常性的新闻，则对市场的影响较小。除了上述因素外，新闻对股票市场的影响还受到一些其他因素的影响，例如股票市场的情况、投资者的心理状态等。

目前研究者主要利用事件研究模型 (Event Study Model)、格兰杰因果模型 (Granger Causality Model)、文本挖掘模型 (Text Mining Model)、情绪分析模型 (Sentiment Analysis Model)、机器学习模型 (Machine Learning Model)、神经网络模型 (Neural Network Model)、贝叶斯网络模型 (Bayesian Network Model)，研究新闻对股票市场的影响。

对于股票市场的波动以及股票价格的大幅度跳跃，Neuhierl, A.等人^[49]研究了各种类型的企业新闻发布对股票价格反应的影响。Manela, A.和 A. Moreira^[51]利用新闻内容的文本分析来构建美国市场的新闻隐含波动率，发现它能很好地预测 VIX、标普 500 指数的波动率和市场收益的实现波动率。Baker, S.R.等人^[48]在 16 个不同国家的市场层面上探讨了跳跃的新闻来源。他们的结果显示，股市跳跃的新闻来源，以及该来源的清晰度，对未来的波动性很重要，而且随着时间的推移，其清晰度也在提高。Boudoukh, J.等人^[52]表明，公司新闻的到来占隔夜(交易时间)特异性波动的约 50%(12%)。Glasserman, P. 和 H. Mamaysky^[53]发现，不寻常的负面(正面)的新闻预测了股票和市场层面的回报波动性的增加(减少)。Boudoukh, J.等人^[52]使用了新闻流的特定背景措施来预测世界各地的股票市场波动性。Glasserman, P. 和 H. Mamaysky^[53]还发现，新闻流与股票价格的同期跳跃波动率有关。Baker, S.R.等人^[48]则分析了一个框架，在这个框架中，宏观经济新闻公布前后的资产价格跳跃既反映了对头条新闻的反应，也反映了潜在的因素。同时，他们发现，对非头条新闻的核算对于解释收益率曲线的变化也至关重要。

随着机器学习技术的发展，越来越多的研究开始探讨如何利用机器学习算法来研究新闻对股票市场的影响。首先，一些研究采用了基于情感分析的方法。这些方法试图从新闻中提取出关键词或情感极性，然后使用回归模型或分类模型来预测股票价格的涨跌。例如，Chandra, R. 和 He, Y.^[12]使用了情感分析来预测特定股票的价格变动，发现在预测方面相比于传统方法，情感分析方法表现更好。

除了情感分析，另一些研究使用了更复杂的机器学习算法，如神经网络和深度学习。例如，Kumar, G., Singh, U.P. 和 Jain, S.^[11]利用卷积神经网络和长短时记忆网络来分析新闻对股票市场的影响，结果显示利用这些方法可以有效地预测股票市场的涨跌。

另外，一些研究还利用了自然语言处理技术，例如主题模型和文本分类算法。这些方法可以从大量的新闻报道中发现潜在的话题和主题，然后将其与股票市场数据进行比较，并发现新闻中的潜在话题对股票市场具有显著的影响。

高频股票交易数据具有大量的特征和复杂的模式，而机器学习算法具有挖掘大量数据的能力，并且可以自动学习数据中的复杂模式，从而能够对高频交易数据进行更加准确的预测。同时，机器学习算法可以自动适应不同的市场情况，并对变化做出快速反应。这对于高频交易非常重要，因为市场变化非常快，交易机会非常短暂。使用机器学习算法可以更快速、更准确地捕捉到这些机会。此外，机器学习算法还可以根据历史交易数据和新闻数据的变化来进行实时

调整，以提高预测的准确性。这种动态调整可以更好地适应市场变化，并减少错误的预测[15, 16, 17]。

1.3 本文主要内容

股票价格的大幅波动导致财富的突然增加或减少。虽然传统的金融理论认为这种波动是由宏观经济基本面引起的、试图将股票的大幅波动与宏观经济新闻联系起来的经验性尝试只取得了很小的成功。但在微观结构层面上，新闻被纳入证券价格的过程需要更细微的研究。目前对于新闻与股票交易的关系，研究者聚焦于股票价格的预测与股票波动性的预测。

本论文利用 2010 年从交易日 1 月 5 日至 12 月 31 日共 5757 支美国市场上的股票的 TAQ 从 9:30–16:00 以 15min 为一个时间区间的高频交易数据以及其对应的 Raven Pack 新闻数据。我们首先提取出 Raven Pack 新闻数据对应的 19 个连续型数值变量以及包括新闻类别在内的 3 个类别变量，并将每条新闻对应至最近的交易时间区间，计算出该新闻发生的时间区间内的收益率 r ，该新闻发生后的第一个时间区间 I、第二个时间区间 II、第三个时间区间 III 的高频交易股票收益率 r_I, r_{II}, r_{III} 。通过将 r, r_I, r_{II}, r_{III} 作为因变量依次整体线性回归到新闻对应的自变量上，观察对应系数的显著性，探究在新闻市场上是否存在信息的延迟反应，相比以往的研究，Wood, Robert^[26]利用 TAQ 的高频交易数据，但未考虑新闻信息流对股票市场的影响，或者 Chan, Wesley S^[25]仅利用新闻的标题信息来判断其对股票的影响，本论文通过 Raven Pack 数据集增加了更加丰富的新闻变量，包括了 News_type 变量对新闻的展示形式（例如全文可见或仅部分可见），Category（包括了新闻的细分类别：例如事件包括分析师建议[40]，收益公告[41]以及[42]，并购[43, 44, 45]，分拆[46]，以及私人股权收购[47]等类别信息），还有采用文本分析的各种方法对新闻的情感进行判断得分。考虑了新闻多维度特征对股票高频交易收益率的影响，回归系数的结果与方向更加稳健，能够观察到更加明显股票对新闻各变量体现在收益率上的响应速度。

由于线性回归建设模型各变量之间服从简单的相加关系，未考虑变量之间的相互作用或者非线性关系，因此本论文按照 6: 2: 2 的比例根据时间顺序将数据分为训练集、验证集、以及测试集，并利用回归树模型利用新闻变量预测股票高频交易发生时间区间后时间区间 I、II、III 的收益率。与本论文不同，Chen, Sipeng 和 Gang Li^[28]利用 Raven Pack 数据集，研究了股票期权隐含波动率的信息内容，通过衡量各种类型的新闻的到达强度和幅度，发现这些新闻措施都与同期股票收益率波动率正相关，而且其中很多都可以通过隐含波动率来预测。隐含波动率对未来已实现波动率的预测能力中约有 28% 是由于其对这些新闻指标的预测能力，而大部分的预测能力来自于对预定和未预定新闻的到达强度的预测。基本面新闻的预测能力高于非基本面新闻的预测能力。并且 Chen, Sipeng 和 Gang Li^[28]考虑的模型为了可解释性的需要仍为线性关系，未考虑变量可能的非线性关系对已实现波动率的预测效果。根据本论文的两个衡量标准 MSE 与 $R^2_{testing\ set}$ ，发现相比线性模型，回归树在训练集上的 R 方与测试集对应的样本外 R 方都有显著

的提高。回归树的表现肯定了构建非线性模型对基于新闻特点预测股票高频交易收益率的效果。最后本论文构建了隐藏层数目分别为 1、2、3 的神经网络，来探究更复杂的非线性关系能否有更好的预测效果，结果显示，尽管神经网络需要更长的时间训练，但能够捕捉到更多的非线性数据特征，在测试集上基于比较标准有更好的效果，本论文神经网络的搭建以及学习率的选取参考了 Shihao Gu 等人^[19]通过机器学习进行资产定价的研究。

本论文发现高频股票交易市场收益率与新闻事件发生对应的关系建立需要建立非线性模型，在非线性的复杂度上，神经网络相比回归树能够捕捉更多的高频交易市场中的信息，在预测上有更好的效果。而无论加入再多的变量，简单的线性模型也无法捕捉波动性极大的股票交易信息，本论文未来可以使用更多的非线性模型来预测高频交易市场的收益率。

2 数据介绍及处理

本节为本论文使用的研究的数据集及对数据集中包含变量的介绍以及相应数据的处理。

2.1 Raven Pack 数据集

Raven Pack 是一家为金融专业人士提供新闻分析和大数据的提供商。提供的数据集涵盖广泛的新闻来源，例如在线新闻媒体、社交媒体和财经博客。并且涵盖广泛的主题，包括公司公告、市场传言和宏观经济新闻。Raven Pack 数据集实时更新，为用户提供最新的突发新闻和事件信息。Raven Pack 数据集的独特之处在于能够对新闻事件提供详细的情绪分析，让用户更好地了解不同类型新闻的市场影响。数据集中的情感分析基于自然语言处理技术，同时考虑了新闻文章的内容和上下文。除了情感分析，该数据集还包括新闻文章中提到的实体的信息，例如公司、人员和位置，这有助于跟踪特定事件对个别公司或行业的影响。Raven Pack 在三个不同的年份相继推出了三个相互排斥的数据包，即道琼斯包 (Dow Jones Package)、新闻发布包 (Press Release Package) 和网络包 (Web Package)。道琼斯数据包涵盖了自 2000 年以来来自道琼斯通讯社 (Dow Johns Newswires)、华尔街日报 (Wall Street Journals)、巴伦周刊 (Barron's) 和市场观察 (MarketWatch) 的所有新闻。新闻发布包从 2004 年开始通过各种信息发布网络跟踪超过 10 万份新闻稿和监管信息披露。网络包从 2007 年开始监测领先出版商和网站的 19,000 多个来源。在 2004 年之前，20% 的公司月度水平观测值没有任何新闻，但在 2004 年之后，这个数字下降到 10% 左右，并在此后保持相对稳定。由于无法确定早期的数据库是完全没有新闻还是没有涵盖新闻，为了保守起见，建议使用 2004 年及以后的数据库，其中道琼斯包和新闻发布包所追踪的消息来源全覆盖，而网络包所追踪的消息来源部分覆盖[28]。

Raven Pack 数据集涵盖的所有变量及对应含义如附表 1 所示。

2.2 TAQ 数据集

Trade And Quote (交易和报价) 数据集是一个高频金融数据集，提供有关各种金融工具 (包括股票、期权和期货) 的交易和报价的详细信息[16]。该数据集由纽约证券交易所 (NYSE) 提供，被学术界和金融专业人士广泛用于研究和分析。TAQ 数据集包括几个与交易和报价相关的变量，包括：**交易变量**：这些变量包括交易的时间和日期、交易的价格和交易量以及交易发生的交易所。该数据集还包括有关交易是买入还是卖出以及是开仓交易还是平仓交易的信息。**报价变量**：这些变量包括最佳出价和要价和交易量，以及报价的时间和日期。该数据集还包括有关报价所在交易所的信息，以及该报价是对先前报价的更改还是取消。**其他变量**：TAQ 数据集还包括一系列其他变量，例如工具标识符、交易条件代码和参与者标识符。TAQ 数据集提供不同粒度级别的数据，从毫秒级数据到每日摘要。这使得研究人员和分析师能够根据他们的特定需求定制他们的分析，并从不同的细节层面深入了解市场动态。总的来说，TAQ 数据

集是金融专业人士和学者的宝贵资源，提供了有关各种金融工具的交易和报价的详细信息。该数据集可用于各种研究和分析目的，例如开发交易算法、分析市场微观结构和测试交易策略。

本论文使用 23052 支股票 1993 年至 2020 年的每 15min 的高频交易数据，交易开始时刻为早上 9 点 30 分，结束时刻为下午 4 点，以 15min 划分时刻共有 26 个时刻，每支股票对应的 TAQ 数据集列为：日期，时间，最低卖价，最低买价，卖价中位数，买价中位数，最高卖价，最高买价。

TAQ 数据集与 Raven Pack 数据集的联合基于数据的 mapping 参考，其中 RAVEN_CRSP 的 mapping 中包含 PERMNO（此为 TAQ 数据集中公司的编号），以及其对应的 RP_ENTITY_ID，可以对应到 Raven Pack 数据集新闻发生对应的实体。

2.3 数据清洗

Chen, Sipeng 和 Gang Li^[28]表明由于在 2004 年之前，20%的公司月度水平观测值没有任何新闻，但在 2004 年之后，这个数字下降到 10%左右，并在此后保持相对稳定。由于无法确定早期的数据库是完全没有新闻还是没有涵盖新闻，为了保守起见，建议使用 2004 年及以后的数据库。因此本论文使用 2004-2020 年的 Raven Pack 新闻数据与对应的 TAQ 数据。由于 23052 支公司的股票不是 2004-2020 所有时期都存在，因此对于一个特定的时间 t ，截面中观察的股票并不是平衡的，并且每年数据量因此本论文以每年为单位，使用不同的股票样本量分别研究。由于 TAQ 和 Raven Pack 数据一一对应的关系，本论文采用在 Mapping 中有对应 RP_ENTITY_ID 的公司数据，最后筛选出 12770 个公司对应的股票。Raven Pack 数据用 SAS 文件格式存储，由于每年的 Raven Pack 数据量巨大（行维度为千万级，列维度为 48），难以在本论文研究环境 Windows 11 64 位，11th Gen Intel (R) Core (TM) [i7-11800H@2.30GHz](#) 16.0GB RAM 完全读入后处理，因此本论文对数据采取按照 100 万行分块读入后依次处理，并以 2010 年的数据集为例进行分析得出结论，2004-2020 其他年份的数据分析结果在附录中呈现。

2.4 新闻时刻确定

Raven Pack 新闻数据集对于服务器捕捉新闻的时间记录在 TIMESTAMP_UTC (e. g 2010-01-01 00:35:00.000) 与 RPNA_DATE_UTC (e. g 2010-01-01) 中，而 TAQ 数据时间为美东时间 (EST)，因此在后续处理中，本论文将新闻 UTC 全部时间转换为 EST。图 1 记录了股票 m 新闻数据与 TAQ 高频交易数据的时间线。

在第 $d-1$ 天 4:00pm 闭市，在第 d 天 9:30am 开市，新闻发生后，原则上当期收益率计算采取新闻发生前的最后一个时间区间的交易价格与新闻发生后的第一个时间区间的交易价格，新闻后续的影响对应的收益率为新闻发生后的最近的时间区间后一个区间。例如 News7, 8 发生后，视作 $N2$ 整体发生在第一个时间区间，其对应的当期收益率为¹：

¹ 关于收益率计算公式的选取，也可以采用对数收益率 $\ln(P_t/P_{t-1})$ ，由于收益率 r 很小，因此 $\ln(P_t/P_{t-1}) \approx (P_t - P_{t-1})/P_{t-1}$ ，

$$r_{d,2} = \frac{P_{d,2} - P_{d,1}}{P_{d,1}} \quad (1)$$

对应的非当期时间区间 I、II、III 的收益率分别为：

$$r_{d,3} = \frac{P_{d,3} - P_{d,2}}{P_{d,2}}, \quad r_{d,4} = \frac{P_{d,4} - P_{d,3}}{P_{d,3}}, \quad r_{d,5} = \frac{P_{d,5} - P_{d,4}}{P_{d,4}} \quad (2)$$

对于 News4, 5, 6 发生在 d-1 天闭市到第 d 天开始期间，视作 N1 整体，认为在闭市到开市这段时间发生的新闻的效应会在第 d 天开市时直接反映在其交易价格上，其对应的当期收益率为：

$$r_{d,1} = \frac{P_{d,1} - P_{d-1,26}}{P_{d-1,26}} \quad (3)$$

Stock m




图 1 股票 m 在第 d-1 天与第 d 天新闻数据与高频交易数据时间线

对于新的一年开市第一天，在本论文探讨的分年份时间中，忽略去年交易日最后一天的信息。

3 数据描述

3.1 描述性统计

每一个年份对应的数据需要即在 mapping 中找到 RP_ENTITY_ID 并且股票有记录 2010 年交易日的数据。表 1 为每一年符合要求的公司股票数目。

表 1 每一年符合观察条件的公司股票数目

2004	2005	2006	2007	2008	2009	2010	2011	2012
6169	6380	6442	6572	6266	5983	5809	5677	5555
2013	2014	2015	2016	2017	2018	2019	2020	
5553	5273	5706	5591	5481	5494	5480	5159	

在 2010 年，不同公司所对应的新闻条数统计信息如表 2 所示，可以看出标准差非常大，各公司对应的新闻数目差异较大，平均而言，一个公司一年对应的新闻数目以千计，但也有公司一年中对应几十万条新闻，可能是由于公司影响力大或有新闻重复报道。

表 2 2010 年各公司股票对应新闻数目统计表

平均数	最大值	最小值	中位数	25%分位数	75%分位数	标准差
2.89e+03	1.31e+06	0	4.91e+02	2.29e+02	1.07e+03	2.46e+04

将公司的每条新闻及其对应的发布时间（精确到秒）转化为时间戳，并将每个公司的股票对应的高频数据的时间区间（精确到分）转化为时间戳，最后合并计算新闻发布对应当期时间区间、对应发生后时间区间 I、发生后时间区间 II、发生后时间区间 III 内的收益率数据，最后 2010 年总共得到 919360 条数据，数值型变量对应的描述性统计如表 4 所示。可以看出对于收益率数据，中位数、平均数和 0 的差异都比较小，其中新闻发生的时间区间收益率的标准差与最小值的绝对值和最大值相比未来时间区间 I、II、III 对应的变量都更大。这初步显示了在高频交易数据中，对于新闻发布，股票市场的快速反应。

图 2 展示了股票高频交易数据以及新闻各连续型变量之间的相关性热力图，结果显示对于新闻高频数据，基于语义分析的新闻的各类情感得分之间有一定的关联性，基于时间与新闻内容重复度、新颖性的测量变量也有一定的相关性。而新闻变量与高频交易收益率数据的相关系数几乎为 0，不同时间区间的收益率之间相关系数也几乎为 0，这符合在一些文献中有效市场假说关于收益率随机分布、难以预测的观点[30-39]。

值得注意的是，虽然股票市场回报随机性的观点得到了强有力的支持，但也有大量的研究提供了反对有效市场假说的证据。此外，股票市场是复杂和动态的，因此没有单一的理论可以捕捉其行为的所有方面。

表 3 2010 年各公司新闻及股票对应时间区间描述性统计量

Descriptive statistic					
Statistic	Median	Mean	St. Dev.	Min	Max
Relevance	100	97.039	15.103	20	100
ESS	50	53.949	13.005	0	100
News_Count	18	160.019	499.725	0	3,683
News_Count_Positive	75	72.350	24.320	0	100
ENS	100	77.855	30.982	0	100
Similarity	6.000	40.533	45.734	0.000	100.000
Novelty	0	1.091e+07	6.266e+07	0	2.002e+09
Global_Novelty	75	66.650	35.092	0	100
Entity_Index	1	1.099	0.355	1	22
Entity_Count	2	2.280	2.461	1	173
Comp_Senti_Score	50	50.161	5.446	4	100
NIP_market	41	43.957	12.003	6	100
PEQ	50	54.198	21.244	0	100
BEE	50	51.752	16.664	0	100
BMQ	50	59.351	32.869	0	100
BAM	50	49.607	10.988	0	100
BCA	50	53.871	21.948	0	100
BER	50	55.583	20.227	0	100
ANL_CHG	50	50.016	6.167	0	100
MCQ	50	60.889	33.503	0	100
Within_Return	0.000	0.004	0.940	-0.980	880.319
I_Return	0.000	0.002	0.062	-0.663	23.163
II_Return	0.000	0.0005	0.044	-0.980	7.750
III_Return	0.000	0.0004	0.122	-0.980	115.507




图 2 股票高频交易数据以及新闻各连续型变量之间的相关性热力图




图 3 数据集类别变量新闻形式 (左:NEWS_TYPE)、新闻细分类别 (右:CATEGORY) 对于新闻类别 (TOPIC) 数据集中共有 899844 条关于 BUSINESS, 19896 条关于 SOCIETY, 74 条关于 POLITICS, 3 条关于 ECONOMY, 这可能导致划分训练集、验证集、测试集时类别变量分布不均匀。

3.2 训练集、验证集与测试集的划分

本论文中, 所有模型的建立以及相应系数的估计或调整均使用训练集: 验证集: 测试集比例为 6: 2: 2。由于股票交易为时间序列数据, 因此训练集、验证集、测试集按照时间顺序选取, 而非随机分散后选取。如图 3 所示一些类别变量的各类别数目差异很大, 会导致其无法在训练集、验证集以及测试集中均匀分布, 无法进行有效的参数调整与统计推断, 因此后续预测中分布不均匀的类别变量不会被考虑加入模型。

3.3 模型评判标准

对于混合模型，通过整个模型在测试集上的 MSE 的 R^2 来判断不同方法的预测效果。定义 N 为 2010 年整体的股票交易与新闻匹配后的测试集数据量：

$$MSE = \frac{\sum_{t \in \text{testing set}} \sum_{i=1}^N (r_{i,t}^{\wedge} - r_{i,t})^2}{\sum_{t \in \text{testing set}} \sum_{i=1}^N 1} \quad (4)$$

$$R^2_{\text{testing set}} = 1 - \frac{\sum_{t \in \text{testing set}} \sum_{i=1}^N (r_{i,t}^{\wedge} - r_{i,t})^2}{\sum_{t \in \text{testing set}} \sum_{i=1}^N (r_{i,t})^2} \quad (5)$$

对于分别每个股票（可以视作加权模型），通过在每个股票的测试集上的 MSE 以及分别的 R^2 来判断不同方法的预测效果。定义 $N_1, \dots, N_M$ 为 2010 年每支公司股票分别与对应欣慰匹配后的测试集数据量：

$$MSE = \frac{\sum_{m=1}^M \sum_{t \in \text{testing set}} \sum_{i_m=1}^{N_m} (r_{i_m,m,t}^{\wedge} - r_{i_m,m,t})^2}{\sum_{m=1}^M \sum_{t \in \text{testing set}} \sum_{i_m=1}^{N_m} 1} \quad (6)$$

$$R^2_{\text{testing set}} = 1 - \frac{\sum_{m=1}^M \sum_{t \in \text{testing set}} \sum_{i_m=1}^{N_m} (r_{i_m,m,t}^{\wedge} - r_{i_m,m,t})^2}{\sum_{t \in \text{testing set}} \sum_{i=1}^N (r_{i,t})^2} \quad (7)$$

其中 $N_1 + N_2 + \dots + N_m = N$ ，混合处理与分别处理，在于估计的参数的组数（训练的模型的个数），混合处理估计一组参数（训练一个模型），分别处理估计多组参数（训练多个模型），直觉上，分别处理考虑每个股票的异质性，在训练集上训练样本更少，能够得到更好的结果。但每个股票可能总体训练集与验证集样本数目较少，有可能在测试集上过拟合。

4 研究方法及其结果

对于多元线性回归、回归树、以及神经网络，均将数据标准化后放入模型。

4.1 多元线性回归：加入新闻变量与公司变量

以收益率为因变量的时间序列模型利用过去的收益率数据来估计未来的收益率，涉及到的变量只有收益率的数据，而多元线性回归模型能够加入协变量即新闻相关的变量来探究其对股票市场收益率的影响。本论文目的在于研究发布的新闻对高频交易数据的后续影响，根据以往研究的假设，收益率数据无明显的季节性趋势，因此能对每一年的数据按照时间顺序划分为训练集与测试集，并采用以下回归模型与训练集来估计系数，并利用估计的系数在测试集上验证效果。

Wood, Robert^[26]使用 1993–2000 的 TAQ 高频交易数据集，通过回归模型验证了不在预期内的影响价格变动的新闻 1. 对同一个时间区间的高频交易数据的影响（本论文中对应于 Within_Return）。2. 将因变量依次设定为后面连续时刻的收益率，研究新闻对高频交易数据的影响速度。（本论文中对应于 I_Return, II_Return, III_Return）。3. 考虑经济体宏观活动，加入哑变量研究股票的收益率对新闻的反应是否依赖于经济体的高、中、低状态。

基于此，本论文研究 2010 年美国市场（US）的 TAQ 高频交易数据集以及对应的新闻数据

集，设定在第 d 天，新闻发布时刻对应的 9:30–16:00 的 15min 时间区间为 t ，股票 m ，股票价格为 p ，股票收益率为 r ，考虑以下新闻变量、公司类别、国家相关变量：

表 4 回归模型变量及对应含义

原始数据集变量名称	变量定义	变量类型	变量模型名称
新闻变量			
RELEVANCE	新闻相关性	数值变量	Relevance
TOPIC	新闻主题	类别变量	Topic
AEV	91 天窗口一个实体新闻事件的数目	数值变量	News_Count
AES	91 天窗口的积极事件比例	数值变量	News_Count_Positive
NEWS_TYPE	报道的形式	类别变量	News_Pre_Type
RP_STORY_EVENT_COUNT	每个新闻故事里总共出现的实体数目	数值变量	Entity_Count
RP_STORY_EVENT_INDEX	每个新闻故事里实体出现的顺序	数值变量	Entity_Index
CSS	复合新闻情感得分	数值变量	Comp_Senti_Score
ESS	新闻情感得分 50 中立 100 积极 0 消极 来自 financial expert	数值变量	ESS
NIP	过去 2h 内新闻对市场的影响得分	数值变量	NIP_market
PEQ	Global Enquity 情感得分	数值变量	PEQ
BEE	Earning's evaluation 情感得分	数值变量	BEE
BMQ	short commentary and editorials on global equity market	数值变量	BMQ
BAM	mergers acquisitions takeovers	数值变量	BAM
BCA	corporate action announcement	数值变量	BCA
BER	earning releases 情感得分	数值变量	BER
ANL_CHG	分析师的建议得分的改变 故事里的公司 过了标准后即有数值，有改变才会被记录 基于语调的新闻情感得分，只与故事里相	数值变量	ANL_CHG
MCQ	关注度最高的公司有关 relevance>90 才会 出现 情感得分	数值变量	MCQ
ENS_SIMILARITY_GAP	该报道与最近相近报道相隔时间	数值变量	Similarity
ENS_ELAPSED	同一件事情与首先的报道相隔距离	数值变量	Novelty
ENS	新闻的新颖程度 24h 内报道同一件事情的 新闻的新颖程度	数值变量	ENS
G_ENS	Globally 新闻的新颖程度 24h 内报道同一 件事情的新闻的新颖程度	数值变量	Global_Novelty
CATEGORY	新闻类别	类别变量	Category

本论文回归部分考虑以下变量及模型：

$$r_{m,t,d} = \frac{p_{m,t,d} - p_{m,t-1,d}}{p_{m,t-1,d}} \quad (8)$$

回归模型 I：考虑新闻全部变量和新闻发布后当期时间区间和未来时间区间 I, II, III 的收益率，假设 **m** 公司对应的新闻在第 **d** 天对应时刻 **t** 发生，其中 $News_{m,t,d}$ 包含所有相关新闻连续变量，

$$r_{m,t+k,d} = \beta_0 + News_{m,t,d}^T \beta + \varepsilon_{m,t+k,d} \quad (9)$$

回归模型 II：考虑新闻传播速度、以及新闻有关的全部变量（新闻连续变量及新闻类别变量），其中 $1 \leq k \leq 26 - t$ ，代表新闻发生后的 k 个时刻，可以通过分别估计的系数的大小判断新闻传播速度。

$$r_{m,t+k,d} = \beta_0 + News_{m,t,d}^T \beta + News_Cate_{m,t,d}^T \gamma + \varepsilon'''_{m,t+k,d} \quad (10)$$

4.2 其他线性回归

如 Shihao Gu 等人^[17]中所展示，在 Ordinary Least Squares 基础之上，通过改变 Loss Function 的形式，例如将 Loss 改为一范数，则为中位数回归，将 Loss 改为 Huber Loss，则可以通过超参数 δ 调节 Loss 中一范数与二范数的比例，能够应对离群点较多的情况，得到更稳健的估计。还可以将数据进行降维，通过方差最大化的约束，投影成几个主成分，再使用偏最小二乘回归 (Partial Least Squares Regression) 或主成分回归 (Principle Component Regression)，但偏最小二乘回归更多的是解决高维问题 ($n < p$)，在本论文中此情况不会发生。通过改变数据的形式，加入连接函数，也可以使用广义线性模型 (General Linear Model) 来估计模型。或者，为了避免模型过拟合的问题以及回归矩阵接近满秩的情况，使用惩罚项，一范数惩罚项即为 Lasso，二范数惩罚项即为岭回归 (Ridge Regression)，二者混合使用则为弹性网 (Elastic Net)，但这些方法起源是解决高维变量估计问题，会对模型变量对应的系数有稀疏性假设，评判的标准更多是 False Discovery Rate。同时，模型的效果极大程度上受 tuning parameter λ 的影响，线性回归或者广义线性回归在股票市场的运用可以参考[17]。本论文的目的是比较线性形式与非线性形式在股票高频数据的预测效果，尽管在一些文献中给出了出于经验的对于线性模型的调节参数的选择标准，但放过多的精力在调节参数如 Huber Loss 对应的 δ ，Lasso 和 Ridge 对应的 λ 不是本文的重点，包括后续的神经网络层数和节点数目的调节也不在本文的讨论范围内。

4.3 回归树

回归树是一种机器学习算法，用于解决回归问题。它是基于树形结构构建的一种预测模型，可以用于预测连续型变量的值。回归树通过将数据集分成若干个子集，并在每个子集上拟合一个简单的线性回归模型来进行预测。具体来说，回归树算法将数据集递归地划分为若干个区域，并在每个区域上拟合一个线性模型，使得区域内所有数据点的误差平方和最小化。

回归树的构建过程从根节点开始，每次选择一个最佳的分裂点，将数据集分成两个子集，并在每个子集上递归地进行分裂，直到达到预定义的停止条件。选择最佳分裂点时，通常使用某种评估指标（如均方误差或平均绝对误差）来衡量分裂后子集的纯度或预测精度。最终得到的回归树模型可以通过对新数据进行递归地分裂和预测来进行预测。

寻找最优切分变量 j 和最优切分点 s 的方法为：

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right] \quad (11)$$

相比于线性回归，回归树能够自适应地根据数据的分布和结构来进行分割和拟合，从而能够捕捉非线性关系，而线性回归则只能处理线性关系。回归树算法将数据集分割为若干个区域，每个区域内的预测结果由该区域内的数据点决定，因此对异常值和噪声具有鲁棒性。而线性回归算法的预测结果受到所有数据点的影响，异常值和噪声会对预测结果产生较大的影响。本论文在训练回归树时，回归树衡量分支质量的指标分别采用 L2 损失 (MSE) 与 Friedman MSE 损失。

4.4 神经网络

神经网络的基本组成单元是神经元 (Neuron)，神经元接收若干个输入信号，将它们加权求和后再加上一个偏置项，然后通过一个激活函数 (Activation Function) 得到输出。激活函数通常是非线性的，如 Sigmoid 函数、ReLU 函数等。

神经网络的结构可以分为输入层、隐藏层和输出层。输入层接收原始的数据输入，隐藏层和输出层分别处理特征和预测结果。隐藏层可以有多个，每个隐藏层包含若干个神经元，隐藏层之间的神经元之间也可以相互连接。输出层通常只有一个或少数几个神经元，输出的结果可以是一个值或一个向量。

相比于回归树，神经网络具有更强的非线性建模能力，能够学习到更为复杂和抽象的特征，从而能够更好地拟合非线性函数。而回归树只能进行局部的线性建模，无法捕捉更为复杂的非线性关系。同时，神经网络对噪声的鲁棒性更好，通过加入正则化项、使用随机梯度下降等方法，对噪声和过拟合进行有效的控制。而回归树容易受到噪声和过拟合的影响。

对于神经网络的泛化能力与可能的偏误，Weinan E. 等人^[29]中给出了详细的分解形式，具体来说，神经网络可能的偏误来自 1. 神经网络的结构能拟合的函数族 $\mathcal{F}$ 与实际函数形式 f_m 的近似误差 (approximation error)。2. 神经网络基于目前数据拟合的非线性函数形式 $\hat{f}_m$ 与实际函数形式 f_m 的估计误差 (estimation error)。神经网络能够拟合的函数形式更加多样，发掘自变量的不同函数形式对因变量的预测效果。本论文分别选取 1、2、3 个隐藏层的神经网络，RELU 作为激活函数，对应每个隐藏层结点 500 个²。本论文中训练网络时，学习率分别设置 $\eta \in \{0.001, 0.01\}$ 。

² 神经网络结构的选取基于目前神经网络的泛化理论，the Universal Approximation Theorem 表明具有单个隐藏层的前馈神经网络包含有限数量的神经元和一个非线性激活函数，可以在给定适当选择权重和偏差的情况下，在其数据域的紧致子集上近似任何连续函数。Kolmogorov's Theorem 表明与单隐藏层神经网络相比，具有两个隐藏层的神经网络可以表示更广泛的函数家




图 4 神经网络结构

4.5 实验结果

本节中，我们将展示 4.1-4.3 提及的全部模型对应的结果，4.5.1 中表 5 为 2010 年全部新闻变量及其对应的当期时间区间与未来时间区间 I、III 后的股票收益率的回归结果，附表 2 的回归结果为不加入与新闻有关的控制类别变量的结果。4.5.2 为回归树对应的未来时间区间 I、II、III 的预测结果，其中新闻类别变量采取 one-hot 独热编码。4.5.3 为神经网络对应的预测结果，类别变量做相应编码处理。

4.5.1 全部数据回归

表 5 的数据显示公司股票的新闻的相关度 (Relevance)、91 天窗口内实体新闻事件数目 (News_Count)，情感得分和市场对股票的评价得分 (BAM, BCA, BER, ANL_CHG) 有延迟响应，在新闻发生后对应 1 的时间区间系数并不显著，对应的 I/II/III 时间区间后系数变得显著。而股票收益率对新闻新颖度的变量例如 ESS, Similarity, Novelty，在当期系数显著，而相应的系数随着时间的推移不再显著，这种趋势和变量的显著性与是否加入新闻类别变量无关。

在 R 方上，加入更多的类别控制变量，对数据变异性的解释比例更高，这是由于更多的类别控制变量能够解释更多的异质性。但解释比例仍然非常小，这可能是由于高频数据中收益率的噪声更大，变化难以仅仅通过新闻捕捉。

对于回归系数的方向，符合本论文预期的是，91 天窗口内实体新闻事件数目、91 天窗口内

族。实际上，具有两个隐藏层的神经网络不仅可以学习和表示连续函数，还可以学习和表示数据中更复杂和错综复杂的关系。具有两个隐藏层的神经网络被认为是通用函数逼近器，因为它可以学习各种非线性和非连续函数。网络的表达能力随着隐藏层中神经元数量的增加和激活函数的选择而增加。

实体新闻积极事件数目方向为正，对于新闻事件数目的正影响的解释为更多关于实体的新闻事件报道使得公司透明度更高，在市场中信息更加充分，或者新闻事件数目多意味着公司规模更大，在波动的股票市场上更加稳健。NIP_market (过去两小时对市场的影响得分)、新闻的复合情感得分、与新闻情感得分有关变量 PEQ、BEE、BMQ、BAM、BCA、BER (earning releases 情感得分) 方向为为正。这些都代表从新闻中传递出的积极信息能够使收益率略微增加。

表 5 回归模型 I、II 结果，加入新闻类别变量

	Dependent variable:			
	Within_Return	I_Return	II_Return	III_Return
	(1)	(2)	(3)	(4)
Relevance	0.002 (0.001)	0.01*** (0.001)	0.002 (0.001)	0.001 (0.001)
Topic-economy	-0.01 (0.58)	0.01 (0.58)	0.02 (0.58)	-0.002 (0.58)
Topic-politics	0.01 (0.12)	-0.02 (0.12)	-0.09 (0.12)	0.01 (0.12)
Topic-society	0.01 (0.01)	-0.004 (0.01)	-0.01* (0.01)	-0.0003 (0.01)
ESS	0.01*** (0.001)	0.01*** (0.001)	-0.002* (0.001)	0.001 (0.001)
News_Count	-0.001 (0.001)	-0.01*** (0.001)	-0.003*** (0.001)	-0.001 (0.001)
News_Count_Positive	0.001 (0.001)	-0.003** (0.001)	-0.01*** (0.001)	-0.002 (0.001)
ENS	-0.003 (0.002)	0.003 (0.002)	0.005** (0.002)	-0.0001 (0.002)
Similarity	0.002* (0.001)	0.003** (0.001)	0.001 (0.001)	0.002 (0.001)
Novelty	-0.001 (0.001)	-0.0004 (0.001)	-0.001 (0.001)	-0.0001 (0.001)
Global_Novelty	0.0002	-0.0002	-0.01***	-0.001



	(0.002)	(0.002)	(0.002)	(0.002)
News_type-HOT-NEWS-FLASH	0.001	-0.004	0.02**	-0.01
H	(0.01)	(0.01)	(0.01)	(0.01)
News_type-NEWS-FLASH	0.01**	0.01***	0.01***	0.003
	(0.003)	(0.003)	(0.003)	(0.003)
News_type-PRESS-RELEASE	-0.002	0.01***	0.004	-0.0000
	(0.003)	(0.003)	(0.003)	(0.003)
News_type-TABULAR-MATERIAL	-0.003	0.002	0.001	-0.01
	(0.01)	(0.01)	(0.01)	(0.01)
Entity_Count	-0.0004	-0.002	0.003**	-0.001
	(0.001)	(0.001)	(0.001)	(0.001)
Entity_Index	0.002*	0.002	-0.001	-0.0002
	(0.001)	(0.001)	(0.001)	(0.001)
Comp_Senti_Score	0.001	0.005***	0.01***	0.001
	(0.002)	(0.002)	(0.002)	(0.002)
NIP_market	-0.002*	-0.005***	-0.004***	-0.001
	(0.001)	(0.001)	(0.001)	(0.001)
PEQ	0.001	0.001	-0.0004	-0.0002
	(0.001)	(0.001)	(0.001)	(0.001)
BEE	-0.0001	0.0002	-0.001	-0.0003
	(0.001)	(0.001)	(0.001)	(0.001)
BMQ	-0.001	-0.002	-0.003	-0.0003
	(0.002)	(0.002)	(0.002)	(0.002)
BAM	0.0004	0.001	-0.003***	0.0004
	(0.001)	(0.001)	(0.001)	(0.001)
BCA	0.001	-0.002	-0.003*	0.0002
	(0.002)	(0.002)	(0.002)	(0.002)
BER	-0.001	0.001	0.003**	-0.001

	(0.001)	(0.001)	(0.001)	(0.001)
ANL_CHG	0.0001	0.01***	0.001	-0.0001
	(0.001)	(0.001)	(0.001)	(0.001)
MCQ	-0.0005	0.0003	-0.001	-0.001
	(0.003)	(0.003)	(0.003)	(0.003)
Constant	-0.001	-0.01***	-0.004**	-0.0005
	(0.002)	(0.002)	(0.002)	(0.002)
Observations	919,360	919,633	919,738	919,772
R ²	0.0001	0.001	0.0002	0.0000
Adjusted R ²	0.0000	0.001	0.0001	-0.0000

备注： *p<0.1; **p<0.05; ***p<0.01

4.5.2 回归树

当因变量分别为当下时间区间、时间区间 I、时间区间 II、时间区间 III 的收益率时，考虑新闻对未来时间区间收益率的预测效果，在不同的随机数设置下训练树模型，并使用 MSE 与费尔德曼均方误差并最终选择训练出的在验证集上均方差最小的模型。可以看出新闻相关程度、过去 2h 内新闻对市场的影响得分、91 天窗口一个实体新闻事件的数目、以及 91 天窗口的积极事件比例、新闻的新颖程度、新闻情感得分，在回归树的分支上以及数据非线性关系的捕捉上有重要作用。

相比之下最好的模型所对应的 MSE 以及 $R^2_{testing\ set}$ 如表 6 所示，大体上随着收益率对应的时间区间越往后，均方误差越大、测试集的 $R^2_{testing\ set}$ 越小，可能是因为随着新闻发布时间间隔越久，可能的混杂因素更多，难以仅根据新闻变量进行预测。

但对比回归模型训练集上极小的 $R^2_{training\ set}$ ，可以看出回归树不仅在训练集同时在测试集的表现有显著提升，相比线性回归，回归树更好的拟合能力。其中表 6 前三列回归树训练时用的 criterion 为 MSE，后三列为 Friedman MSE。MSE 准则为均方误差不纯度准则，在函数调用时指的是左子树的方差与右子树的方差之和最小，Friedman 改进的均方误差不纯度准则在函数调用时指的是左右子树的平均误差最小。

从表 6 的结果，本论文发现使用改进的 Friedman MSE，在训练集上效果相差不大，但在测试集上可以有更小的 MSE 与 $R^2_{testing\ set}$ 。

表 6 不同因变量对应表现最好的回归树在测试集的表现

	I (MSE)	II (MSE)	III (MSE)	I (Friedman)	II (Friedman)	III (Friedman)
MSE	1.569	2.349	2.013	1.483	1.64	1.520
MSE (training set)	0.112	0.057	0.160	0.112	0.06	0.160
MSE (validation set)	1.454	1.644	1.339	1.312	1.383	34.17
$R^2_{testing\ set}$	-0.454	-1.369	-4.512	-0.602	-0.243	-1.617
$R^2_{training\ set}$	0.888	0.943	0.840	0.888	0.943	0.840
$R^2_{validation\ set}$	-0.604	-0.644	-0.339	-0.312	-0.383	-33.17

4.5.3 神经网络

由于训练集、测试集、验证集的百万级数据量，导致不能一次全部放入神经网络进行模型训练，因此在实际训练时，一个 epoch 中，将所有数据分成多个 batch，每次送入一部分数据，进行迭代训练，再通过反向传播。本论文中每个 epoch 对应的 batch size 为 100000，一共迭代 50 个 epoch。采用 RELU 为激活函数，设置学习率 $\eta \in \{0.0001, 0.001\}$ 。训练结果如表 7, 8 所示：

 表 7 不同因变量对应的神经网络在测试集的表现 学习率 $\eta=0.0001$

神经网络隐藏层数	1 层	2 层	3 层
MSE (I_Return)	0.968	0.956	0.961
$R^2_{testing\ set}$ (I_Return)	0.033	0.044	0.039
MSE (II_Return)	1.049	1.048	1.045
$R^2_{testing\ set}$ (II_Return)	-0.051	-0.047	-0.045
MSE (III_Return)	1.101	1.10	1.095
$R^2_{testing\ set}$ (III_Return)	-0.101	-0.098	-0.093

 表 8 不同因变量对应的神经网络在测试集的表现 学习率 $\eta=0.001$

神经网络隐藏层数	1 层	2 层	3 层
MSE (I_Return)	0.967	0.964	0.960
$R^2_{testing\ set}$ (I_Return)	0.033	0.036	0.042
MSE (II_Return)	1.052	1.049	1.045
$R^2_{testing\ set}$ (II_Return)	-0.052	-0.049	-0.045
MSE (III_Return)	1.103	1.104	1.095
$R^2_{testing\ set}$ (III_Return)	-0.103	-0.104	-0.095

相比回归树以及普通的线性回归，无论是在测试集上 MSE 的表现，还是对应的样本外 $R^2_{testing\ set}$ ，神经网络有显著的提升，同时神经网络不同的层数对应的 MSE 有细微下降趋势，2 个与 3 个隐藏层在测试集的拟合效果显著比 1 个隐藏层更好，说明了增加神经网络的隐藏层数量能够增加神经网络能够表示的非线性关系。但 3 个隐藏层的结果不一定比 2 个隐藏层结果更好，可能是因为 3 个隐藏层增加了更多的参数量，同时由于损失函数没有增加正则化项，导致了一定程度上的过拟合。对比学习率分别为 0.001 与 0.0001，发现不同的学习率对最后训练结果的影响不大。如果学习率过大，则神经网络无法收敛，学习率 0.0001 至 0.01 都为合适的步长。

5 总结

本论文基于 Raven Pack 高频新闻数据与 TAQ 高频交易数据集，在新闻发布当期节点、未来节点 I/II/III 共四个时间节点上研究了对应的新闻数据与股票高频交易收益率关系，建立了 1. 总体混合线性回归，2. 回归树（分别基于 MSE 与 Friedman MSE），3. 学习率分别为 0.0001 与 0.001，隐藏层分别为 1 至 3 的神经网络模型来探究新闻数据对公司高频交易收益率的影响，并基于 MSE 与测试集上的可决系数 R 方比较了各模型的表现。

从总体回归的可决系数上，本论文发现，简单的线性关系无法捕捉高频交易市场的噪音，线性回归模型虽然显著，但能够解释的股票收益率波动比例十分小。而从回归系数的显著性及其方向上，本论文发现显示公司股票的新闻的相关度 (Relevance)、91 天窗口内实体新闻事件数目 (News_Count)，情感得分和市场对股票的评价得分 (BAM, BCA, BER, ANL_CHG) 有延迟响应，在新闻发生后对应 I 的时间区间系数并不显著，对应的 I/II/III 时间区间后系数变得显著。而股票收益率对新闻新颖度的变量例如 ESS, Similarity, Novelty，在当期系数显著，而相应的系数随着时间的推移不再显著，这种趋势和变量的显著性与是否加入新闻类别变量无关。

在模型的选择上，本论文发现混合回归模型无法考虑到公司之间的内部差异，同时整体对波动性的解释比例十分小，测试集上得到的预测结果基本为 0。据此，本论文认为线性模型无法捕捉高频交易市场的信息。

使用回归树模型捕捉部分非线性信息，训练的模型在测试集与训练集上的表现上有了显著的提高，本论文认为回归树相比线性回归模型捕捉了更多新闻信息与高频股票交易信息之间的非线性关系，能够有更好的预测效果。

而使用神经网络模型，则相比回归树模型在测试集上效果有了更大的提升，本论文使用的神经网络模型隐藏层数目为 1 至 3，每个隐藏层节点数目为 500 个，学习率分别为 0.0001 与 0.01。研究发现学习率的设置对于最后收敛的结果基本没有影响，相比 1 个隐藏层的神经网络，2-3 层隐藏层对模型拟合有显著的提升，能够捕捉更多、更复杂的非线性关系，但使用 3 个隐藏层需要训练更多的参数，在不加正则化项的情况下可能会造成模型过拟合。



最后，本论文发现高频股票交易市场收益率与新闻事件发生对应的关系建立需要建立非线性模型，线性模型无法捕捉波动性极大的股票交易信息，神经网络是一个好的开始，未来可以使用更多的非线性模型来研究高频交易市场。

作者签名： 吕秋燃



參考文獻

- [1] Liu, Y., Zeng, Q., Yang, H., Carrio, A. (2018) . Stock Price Movement Prediction from Financial News with Deep Learning and Knowledge Graph Embedding. In: Yoshida, K., Lee, M. (eds) Knowledge Management and Acquisition for Intelligent Systems. PKAW 2018. Lecture Notes in Computer Science, vol 11016. Springer, Cham.
- [2] S. Mohan, S. Mullapudi, S. Sammeta, P. Vijayvergia and D. C. Anastasiu, "Stock Price Prediction Using News Sentiment Analysis," 2019 IEEE Fifth International Conference on Big Data Computing Service and Applications (BigDataService) , Newark, CA, USA, 2019, pp. 205-208.
- [3] Wu, JM-T, Li, Z, Srivastava, G, Tasi, M-H, Lin, JC-W. A graph-based convolutional neural network stock price prediction with leading indicators. Softw Pract Exper. 2021; 51: 628– 644.
- [4] TETLOCK, P.C. (2007) , Giving Content to Investor Sentiment: The Role of Media in the Stock Market. The Journal of Finance, 62: 1139-1168.
- [5] FOUCAULT, T., HOMBERT, J. and ROȘU, I. (2016) , News Trading and Speed. The Journal of Finance, 71: 335-382.
- [6] BAKER, M. and WURGLER, J. (2006) , Investor Sentiment and the Cross-Section of Stock Returns. The Journal of Finance, 61: 1645-1680.
- [7] Fama, E.F., Fisher, L., Jensen, M.C., & Roll, R. (1969) . The Adjustment of Stock Prices to New Information. Capital Markets: Market Efficiency eJournal.
- [8] Granger, C. W. (1969) . Investigating causal relations by econometric models and cross-spectral methods. Econometrica, 37 (3) , 424-438.
- [9] Loughran, T., & McDonald, B. (2011) . When is a liability not a liability? Textual analysis, dictionaries, and 10-Ks. Journal of Finance, 66 (1) , 35-65.
- [10] Ding, X., Zhang, Y., Liu, T., & Duan, Y. (2014) . Deep learning for event-driven stock prediction. In Proceedings of the 2014 SIAM International Conference on Data Mining (pp. 912-920) . SIAM.
- [11] Kumar, G., Singh, U.P. & Jain, S. Swarm Intelligence Based Hybrid Neural Network Approach for Stock Price Forecasting. Comput Econ 60, 991–1039 (2022) .
- [12] Chandra, R., & He, Y. (2021) . Bayesian neural networks for stock price forecasting before and during COVID-19 pandemic. Plos one, 16 (7) , e0253217.
- [13] Shunxiang Zhang, Hongbin Yu, Guangli Zhu. (2022) An emotional classification method of Chinese short comment text based on ELECTRA. Connection Science 34:1, pages 254-273.
- [14] Bharathi.Sv, Shri & Geetha, Angelina. (2017) . Sentiment Analysis for Effective Stock Market Prediction. International Journal of Intelligent Engineering and Systems. 10. 146-154.
- [15] Feng, M., & Xie, S. (2018) . A deep learning framework for financial time series using stacked autoencoders and long-short term memory. PloS one, 13 (7) , e0197371.
- [16] Lipton, Z. C., Berkowitz, J., & Elkan, C. (2015) . A critical review of recurrent neural networks for sequence learning. arXiv preprint.
- [17] Zhang, G. P. (2003) . Time series forecasting using a hybrid ARIMA and neural network

model. *Neurocomputing*, 50, 159-175.

[18] Andersen, Archakov, I., Grund, L., Hautsch, N., Li, Y., Nasekin, S., Nolte, I., Pham, M. C., Taylor, S., & Torodov, V. (2021). A Descriptive Study of High-Frequency Trade and Quote Option Data. *Journal of Financial Econometrics*, Volume 19, Issue 1, Winter 2021, Pages 128–177.

[19] Shihao Gu, Bryan Kelly, Dacheng Xiu, Empirical Asset Pricing via Machine Learning, *The Review of Financial Studies*, Volume 33, Issue 5, May 2020, Pages 2223–2273.

[20] Narayan, Paresh Kumar, and Deepa Bannigidadmath. “Does Financial News Predict Stock Returns? New Evidence from Islamic and Non-Islamic Stocks.” *Pacific-Basin finance journal* 42 (2017) : 24–45. Web.

[21] DELLAVIGNA, STEFANO, and JOSHUA M. POLLET. “Investor Inattention and Friday Earnings Announcements.” *The Journal of finance* (New York) 64.2 (2009) : 709–749. Web.

[22] Jeon, Yoontae. “News as Sources of Jumps in Stock Returns: Evidence From 21 Million News Articles for 9000 Companies.” *SSRN Electronic Journal* (2020) : n. pag. Web.

[23] Jiang, Hao, Sophia Zhengzi Li, and Hao Wang. “Pervasive Underreaction: Evidence from High-Frequency Data.” *Journal of financial economics* 141.2 (2021) : 573–599. Web.

[24] GARCIA, DIEGO. “Sentiment During Recessions.” *The Journal of finance* (New York) 68.3 (2013) : 1267–1300. Web.

[25] Chan, Wesley S. “Stock Price Reaction to News and No-News: Drift and Reversal after Headlines.” *Journal of financial economics* 70.2 (2003) : 223–260. Web.

[26] Wood, Robert. “The Effects of Inflation News on High Frequency Stock Returns.” 77.3 (2004) : 547–574. Print.

[27] Baker, Scott R et al. *What Triggers Stock Market Jumps?* Centre for Economic Performance, LSE, 2021. Print.

[28] Chen, Sipeng, and Gang Li. “Why Does Option Implied Volatility Forecast Realized Volatility? Evidence from News Events.” *SSRN Electronic Journal* n. pag. Web.

[29] Weinan E. (2020). *Towards a Mathematical Understanding of Neural Network-Based Machine Learning: What We Know and What We Don't*. *CSIAM Transactions on Applied Mathematics*, 1 (4), 561–615.

[30] Fama, Eugene F. (1965). "The Behavior of Stock-Market Prices". *The Journal of Business*, 38 (1), 34-105.

[31] Fama, Eugene F. (1970). "Efficient Capital Markets: A Review of Theory and Empirical Work". *The Journal of Finance*, 25 (2), 383-417.

[32] Samuelson, Paul A. (1965). "Proof That Properly Anticipated Prices Fluctuate Randomly". *Industrial Management Review*, 6 (2), 41-49.

[33] Malkiel, Burton G. (1973). "A Random Walk Down Wall Street". W. W. Norton & Company.

- [34] Lo, Andrew W., & MacKinlay, A. Craig. (1988) . "Stock Market Prices Do Not Follow Random Walks: Evidence from a Simple Specification Test". *Review of Financial Studies*, 1 (1) , 41-66.
- [35] Fama, Eugene F., & French, Kenneth R. (1988) . "Permanent and Temporary Components of Stock Prices". *Journal of Political Economy*, 96 (2) , 246-273.
- [36] Poterba, James M., & Summers, Lawrence H. (1988) . "Mean Reversion in Stock Prices: Evidence and Implications". *Journal of Financial Economics*, 22 (1) , 27-59.
- [37] Campbell, John Y., Lo, Andrew W., & MacKinlay, A. Craig. (1997) . "The Econometrics of Financial Markets". Princeton University Press.
- [38] Shiller, Robert J. (2000) . "Irrational Exuberance". Princeton University Press.
- [39] Cont, Rama. (2001) . "Empirical properties of asset returns: Stylized facts and statistical issues". *Quantitative Finance*, 1 (2) , 223-236.
- [40] Hayunga, D. K., and P. P. Lung, 2014, Trading in the options market around financial analysts' consensus revisions, *Journal of Financial and Quantitative Analysis*, 49, 725- 747
- [41] Xing, Y., X. Zhang, and R. Zhao, 2009, What does individual option volatility smirk tell us about future equity returns? *Journal of Financial and Quantitative Analysis*, 45, 641-662.
- [42] Atilgan, Y., 2014, Volatility spreads and earnings announcement returns, *Journal of Banking and Finance*, 38, 205-215.
- [43] Cao, C., Z. Chen, and J. Griffin, 2005. Informational content of option volume prior to takeovers, *Journal of Business*, 78, 1073-1109.
- [44] Chan, K., L. Ge, and T.-C. Lin, 2015, Informational content of options trading on acquirer announcement return, *Journal of Financial and Quantitative Analysis*, 50, 1057-1082.
- [45] Augustin, P., M. Brenner, and M. G. Subrahmanyam, 2019, Informed options trading prior to takeover announcements: Insider trading?, *Management Science*, 65, 5697-5720.
- [46] Augustin, P., M. Brenner, J. Hu, and M. G. Subrahmanyam, 2020, Are corporate spin-offs prone to insider trading?, *Critical Finance Review*, 9, 115-155.
- [47] Acharya, V. V., and T. C. Johnson, 2010. More insiders, more insider trading: Evidence from private-equity buyouts, *Journal of Financial Economics*, 98, 415-650.
- [48] Baker, S.R., Bloom, N., Davis, S., Sammon, M., 2021. What triggers stock market jumps? Unpublished working paper. Becker Friedman Institute for Economics, University of Chicago.
- [49] Neuhierl, A., Scherbina, A., Schiusene, B., 2013. Market reaction to corporate press releases. *J. Financ. Quant. Anal.* 48 (4) , 1207–1240.
- [50] Gurkaynak, " R.S., Kisacikoglu, ~ B., Wright, J.H., 2020. Missing events in event studies: identifying the effects of partially measured news surprises. *Am. Econ. Rev.* 110 (12) , 3871–3912.
- [51] Manela, A. and A. Moreira, 2017, News implied volatility and disaster concerns, *Journal of Financial Economics*, 123, 137-162.

-
- [52] Boudoukh, J., R. Feldman, S. Kogan, and M. Richardson, 2019, Information, trading, and volatility: Evidence from firm-specific news, *Review of Financial Studies*, 32, 993-1033.
- [53] Glasserman, P. and H. Mamaysky, 2019, Does unusual news forecast market stress?, *Journal of Financial and Quantitative Analysis*, 54, 1937-1974.
- [54] Calomiris, C. W. and H. Mamaysky, 2019, How news and its context drive risk and returns around the world, *Journal of Financial Economics*, 133, 299-336.
- [55] Jeon, Y., T. H. McCurdy, and X. Zhao, 2019, News as sources of jumps in stock returns: Evidence from 21 million news articles for 9000 companies, Working Paper, Ryerson University, University of Toronto, and Georgetown University.

附录

附表 1 Raven Pack 数据集变量及对应含义

TIMESTAMP_UTC	新闻发布被服务器捕获时间
ENTITY_NAME	实体名称 e. g. Sprint Corp.
ENTITY_TYPE	实体类型 e. g. COMP 共 5 个
POSITION_NAME	新闻涉及的职业类别 e. g. 医生护士
COUNTRY_CODE	国家名称
RP_ENTITY_ID	实体编号，用于 Mapping 确定对应的 TAQ 数据
新闻有关变量	
RELEVANCE	相关性 值越大说明该实体与该新闻越有关
主题范围: Topic>Group>Type>subType>Property>category	
TOPIC	主题 business society economy politics
GROUP	二级主题 主题细分后
SUB_TYPE	TYPE 的细分
TYPE	主题的分类
PROPERTY	实体在新闻中扮演的角色 e. g. victim/organizer/importer
EVALUATION_METHOD	量化改变的形式 YOY (依年变化) QOQ (依季度变化)
MATURITY	新闻的有效期
CATEGORY	新闻类别 business-contract bombing-attack-target
ESS	新闻情感得分 50 中立 100 积极 0 消极 来自 financial expert
AES	91 天窗口的积极事件比例
AEV	91 天窗口一个实体新闻事件的数目
ENS	新闻的新颖程度 24h 内报道同一件事情的新闻的新颖程度
ENS_SIMILARITY_GAP	与最近相近报道相隔时间
ENS_KEY	帮助分类、标记、mapping 的 key



ENS_ELAPSED	同一件事情与首先的报道相隔距离
G_ENS	Globally 新闻的新颖程度 24h 内报道同一件事情的新闻的新颖程度
G_ENS_SIMILARITY_GAP	Globally 与最近相近报道相隔时间
G_ENS_KEY	Globally 帮助分类、标记、mapping 的 key
G_ENS_ELAPSED	Globally 同一件事情与首先的报道相隔距离
EVENT_SIMILARITY_KEY	相似的事件有相同的 key
NEWS_TYPE	报道的形式:共 5 个 是不是全文/有没有标题/有没有正文/是否由供应商发出
SOURCE	新闻来源 B5569E DJ 18A55F
RP_STORY_ID	新闻的独特标记
RP_STORY_EVENT_INDEX	每个新闻故事里实体出现的顺序
RP_STORY_EVENT_COUNT	每个新闻故事里总共出现的实体数目
PRODUCT_KEY	哪个包包含的这个事件 e. g. DJ-EQ
COMPANY	公司标记
ISIN	1 个公司只有一个国际编码
CSS	复合新闻情感得分 大于 50 代表积极 PEQ BEE BMQ BAM BCA 复合
NIP	过去 2h 内新闻对市场的影响得分 50 代表没有影响 大于 50 代表高影响 小于 50 代表低影响或者影响未知
PEQ	Global Enquity 情感得分 0 代表消极 50 代表中立 100 代表积极
BEE	Earning's evaluation 情感得分 0 代表消极 50 代表中立 100 代表积极
BMQ	short commentary and editorials on global equity market 情感得分 0 代表消极 50 代表中立 100 代表积极
BAM	mergers acquisitions takeovers 情感得分 0 代表消极 50 代表中立 100 代表积极
BCA	corporate action announcement 情感得分 0 代表消极 50 代表中立 100 代表积极
BER	earning releases 情感得分 0 代表消极 50 代表中立 100 代表积极

ANL_CHG

分析师的建议得分的改变 故事里的公司过了
标准后即有数值，有改变才会被记录，0 代表
下降 50 代表不变 100 代表评分上升

MCQ

基于语调的新闻情感得分，只与故事里相关度
最高的公司有关 relevance>90 才会出现 情感
得分 0 代表消极 50 代表中立 100 代表积极

附表 2 回归模型 I、II 结果，不加入新闻类别变量

	Dependent variable:			
	Within_Return	I_Return	II_Return	III_Return
	(1)	(2)	(3)	(4)
Relevance	0.0017 (0.0014)	0.0055*** (0.0014)	0.0012 (0.0014)	0.0004 (0.0014)
ESS	0.0060*** (0.0012)	0.0100*** (0.0012)	-0.0013 (0.0012)	0.0011 (0.0012)
News_Count	-0.0012 (0.0012)	-0.0078*** (0.0012)	-0.0040*** (0.0012)	-0.0006 (0.0012)
News_Count_Positive	0.0010 (0.0011)	-0.0026** (0.0011)	-0.0081*** (0.0011)	-0.0017 (0.0011)
ENS	-0.0037 (0.0023)	0.0037 (0.0023)	0.0048** (0.0023)	-0.0002 (0.0023)
Similarity	0.0024* (0.0014)	0.0031** (0.0014)	0.0009 (0.0014)	0.0021 (0.0014)
Novelty	-0.0007 (0.0012)	-0.0002 (0.0012)	-0.0008 (0.0012)	-0.0001 (0.0012)
Global_Novelty	0.0014 (0.0021)	0.0004 (0.0021)	-0.0050** (0.0021)	-0.0003 (0.0021)
Entity_Count	-0.0012 (0.0011)	-0.0031*** (0.0011)	0.0018* (0.0011)	-0.0012 (0.0011)
Entity_Index	0.0022	0.0014	-0.0016	-0.0001



	(0.0014)	(0.0014)	(0.0014)	(0.0014)
Comp_Senti_Score	0.0004	0.0049***	0.0072***	0.0011
	(0.0018)	(0.0018)	(0.0018)	(0.0018)
NIP_market	-0.0017	-0.0050***	-0.0036***	-0.0013
	(0.0011)	(0.0011)	(0.0011)	(0.0011)
PEQ	0.0008	0.0006	-0.0007	-0.0002
	(0.0013)	(0.0013)	(0.0013)	(0.0013)
BEE	0.0001	0.0001	-0.0009	-0.0003
	(0.0013)	(0.0013)	(0.0013)	(0.0013)
BMQ	-0.0007	-0.0022	-0.0030	-0.0004
	(0.0025)	(0.0025)	(0.0025)	(0.0025)
BAM	0.0004	0.0011	-0.0036***	0.0005
	(0.0013)	(0.0013)	(0.0013)	(0.0013)
BCA	0.0005	-0.0027*	-0.0035**	0.0001
	(0.0015)	(0.0015)	(0.0015)	(0.0015)
BER	-0.0005	0.0010	0.0035***	-0.0005
	(0.0012)	(0.0012)	(0.0012)	(0.0012)
ANL_CHG	0.0002	0.0112***	0.0014	-0.0001
	(0.0011)	(0.0011)	(0.0011)	(0.0011)
MCQ	-0.0004	0.0013	-0.0008	-0.0005
	(0.0026)	(0.0026)	(0.0026)	(0.0026)
Constant	0.000002	0.000001	0.000001	-0.000000
	(0.0010)	(0.0010)	(0.0010)	(0.0010)
Observations	919,360	919,633	919,738	919,772
R ²	0.0001	0.0005	0.0001	0.00001
Adjusted R ²	0.00003	0.0005	0.0001	-0.00001
Residual Std. Error	1.0000 (df = 919339)	0.9998 (df = 919612)	0.9999 (df = 919717)	1.0000 (df = 919751)

致谢

感谢财政金融学院袁佩轩老师，对本篇毕业论文提供了细心的指导，从模型选择、变量选择、论文思路以及独一无二的高频交易数据集，帮助我更深入的了解了股票市场与金融交易市场，或许某一天当我生物统计 PhD 毕业会去 Quant 与市场进行搏杀。

感谢高礼提供的修读金融学学位的机会，感谢高礼研究院的刘薇薇、张小敏、冯瑞老师三年来辅修金融学学位的所有帮助，感谢我自己终于走上了毕业论文提交这一步。

感谢我的所有舍友，感谢李佳瞳同学，感谢谢雨涵同学，感谢王曼乔同学，感谢林旭颖同学，感谢王思然同学，感谢品园六楼 1013 宿舍，小小的 12 平米是我大学里为数不多感到温暖的地方。

本篇论文从数据处理到模型构建得到了很多有趣的结果，感谢自己选择认真完成这篇论文，最后真正学到了很多東西。